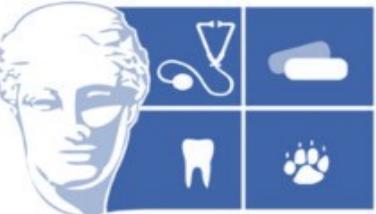




ΑΡΙΣΤΟΤΕΛΕΙΟ
ΠΑΝΕΠΙΣΤΗΜΙΟ
ΘΕΣΣΑΛΟΝΙΚΗΣ

Συσχέτιση μεταξύ δυο ποσοτικών μεταβλητών – Γραμμική εξάρτηση

Κωνσταντίνος Ι. Μπουγιούκας, PhD



ΘΕΣΣΑΛΟΝΙΚΗ

Συσχέτιση δυο ποσοτικών μεταβλητών

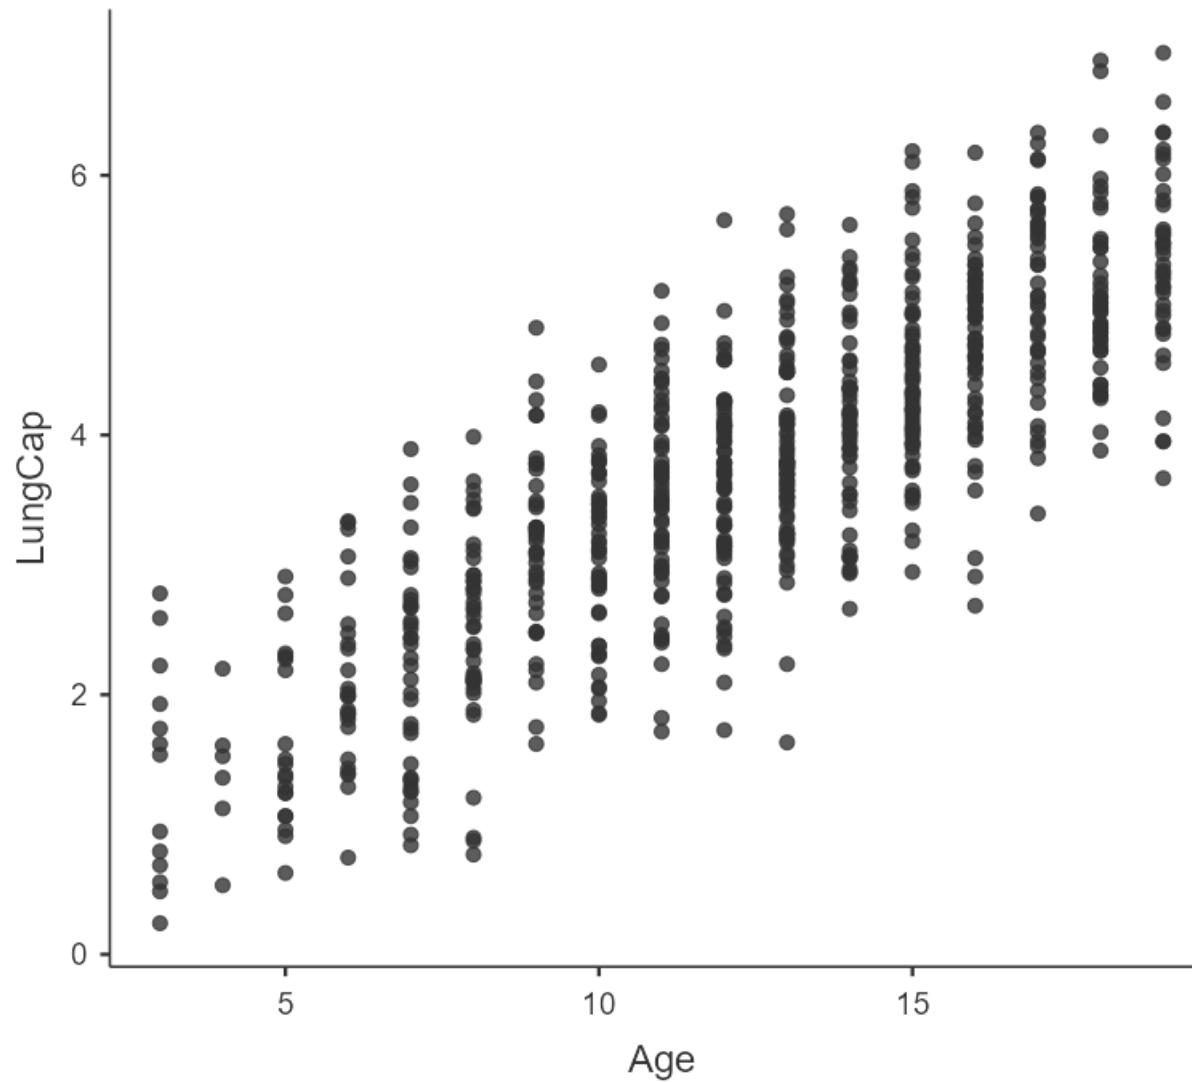
Ερευνητικό ερώτημα

Έστω ότι μια έρευνα προσπαθεί να απαντήσει αν συσχετίζεται η **ηλικία** με την **χωρητικότητα των πνευμόνων**.



Συσχέτιση μεταξύ των μεταβλητών **δεν** συνεπάγεται αιτιολογική σχέση μεταξύ των μεταβλητών

Ερευνητικό ερώτημα- Scatterplot



Συσχέτιση ποσοτικών μεταβλητών

⇒ Συντελεστής συσχέτισης **Pearson r**

(εφαρμόζεται όταν τα δεδομένα στις μεταβλητές ακολουθούν την κανονική κατανομή και υπάρχει γραμμική σχέση)

⇒ Συντελεστής συσχέτισης **Spearman r_s**

(εφαρμόζεται συνήθως όταν τα δεδομένα δεν ακολουθούν την κανονική κατανομή και όταν υπάρχουν ακραίες τιμές)



Συντελεστές συσχέτισης

Ποσοτικοποίηση της **κατεύθυνσης** και της **ισχύος** της σχέσης των δυο ποσοτικών μεταβλητών

Έχουν τιμές: $-1 \leq r \leq +1$ (χωρίς μονάδες)

- **-1** τέλεια αρνητική συσχέτιση
- **+1** τέλεια θετική συσχέτιση
- **= 0** δεν υπάρχει συσχέτιση

Έλεγχος Υποθέσεων

$$H_0: \rho = 0$$

$$H_1: \rho \neq 0$$



Συντελεστής συσχέτισης του Pearson r (Pearson's correlation coefficient)

- Δείχνει την κατεύθυνση και την ισχύ μιας **γραμμικής** συσχέτισης
- Οι δυο ποσοτικές μεταβλητές (X, Y) πρέπει να ακολουθούν την **κανονική κατανομή**
- Οι **ακραίες τιμές** μπορεί να επηρεάσουν σημαντικά τον συντελεστή του Pearson
- Περιορίζεται η χρήση του όταν υπάρχουν **υπο-ομάδες**



Βαθμός (ένταση) της συσχέτισης δυο ποσοτικών μεταβλητών

| | |
|---|------------------------------|
| $-0.5 < r \leq -0.3$ ή $0.3 \leq r < 0.5$ | ασθενής συσχέτιση |
| $-0.7 < r \leq -0.5$ ή $0.5 \leq r < 0.7$ | μέτρια συσχέτιση |
| $-0.8 < r \leq -0.7$ ή $0.7 \leq r < 0.8$ | ισχυρή συσχέτιση |
| $-1.0 \leq r \leq -0.8$ ή $0.8 \leq r \leq 1.0$ | πολύ ισχυρή συσχέτιση |

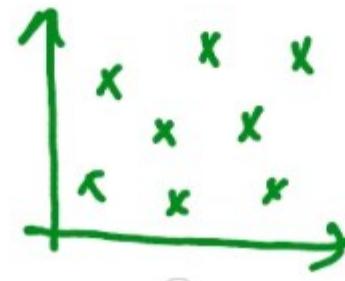


Συντελεστής συσχέτισης του Pearson r (Pearson's correlation coefficient)

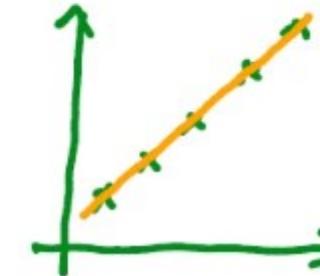
-1
PERFECT
NEGATIVE
CORRELATION



0
NO
CORRELATION

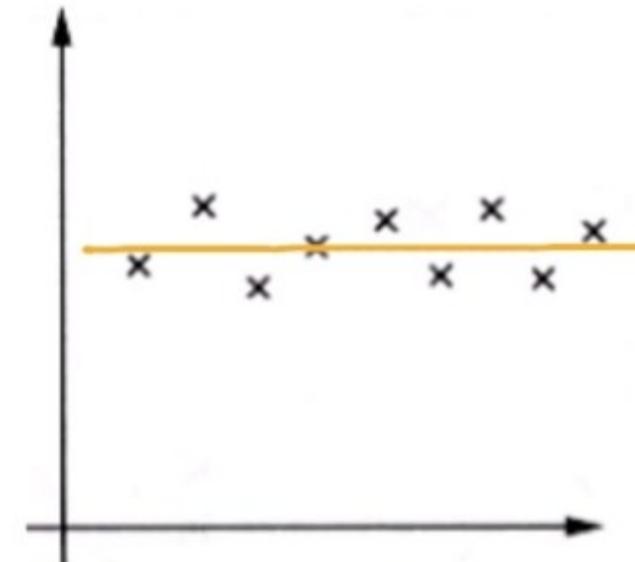
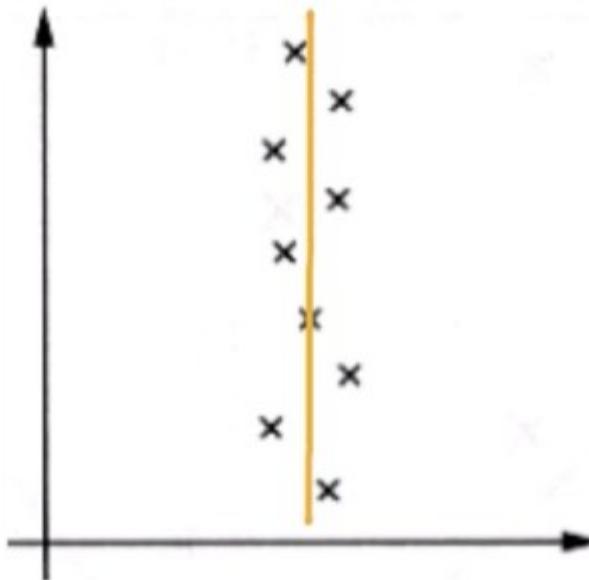


1
PERFECT
POSITIVE
CORRELATION



Συντελεστής συσχέτισης του Pearson r (Pearson's correlation coefficient)

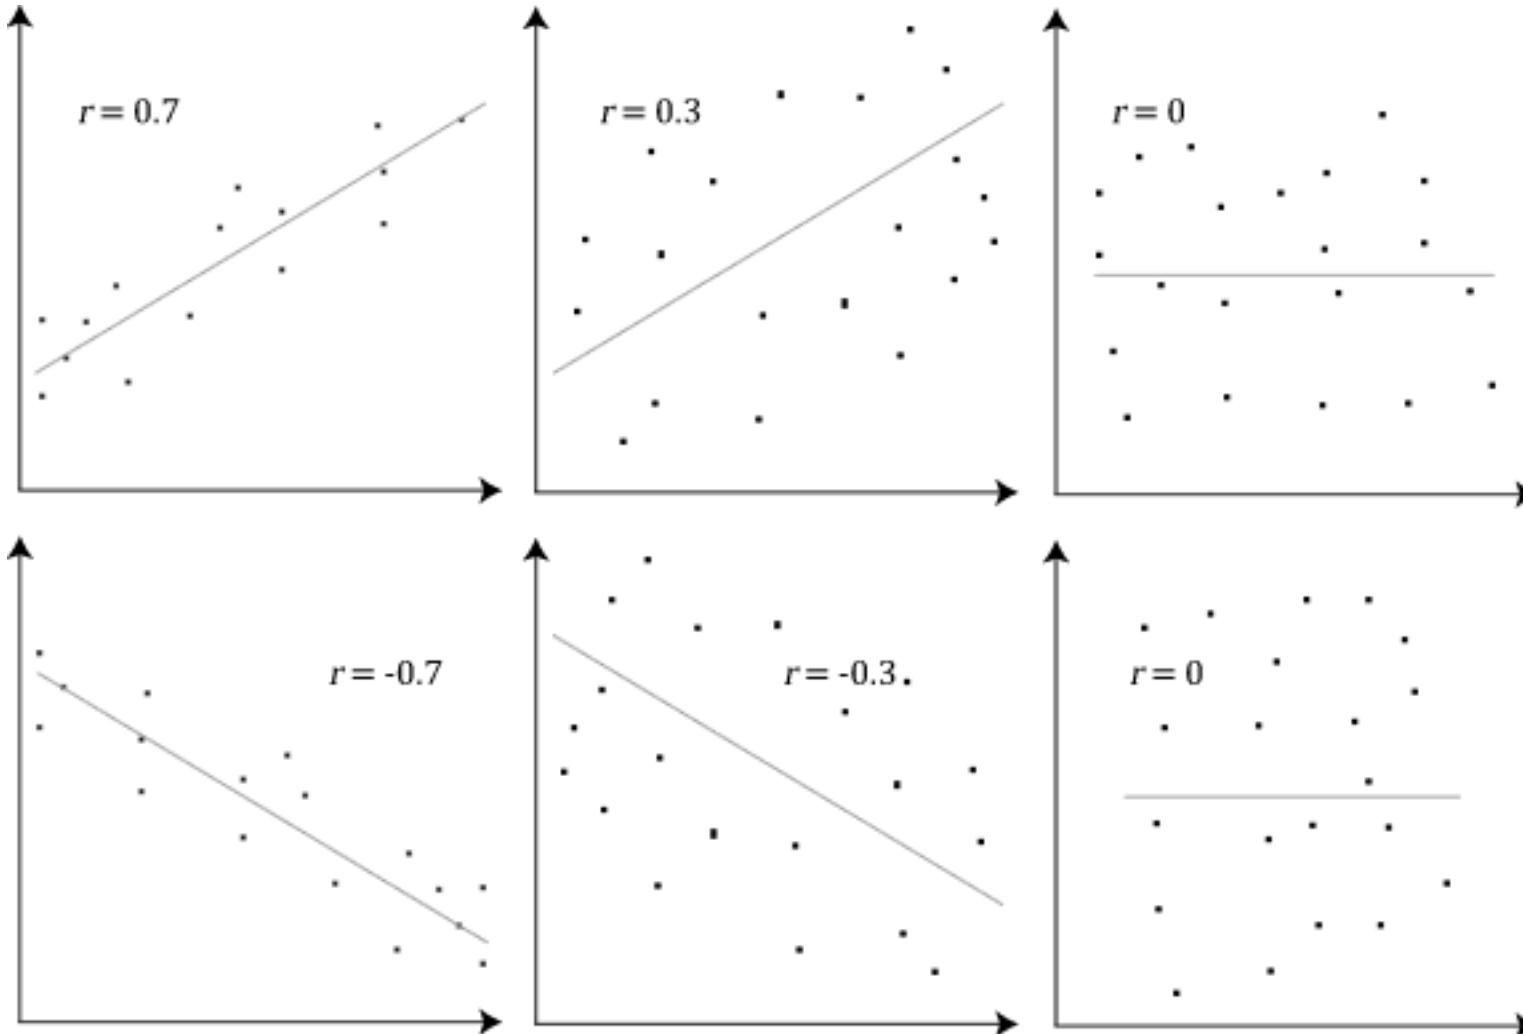
CORRELATION COEFFICIENT NEAR 0



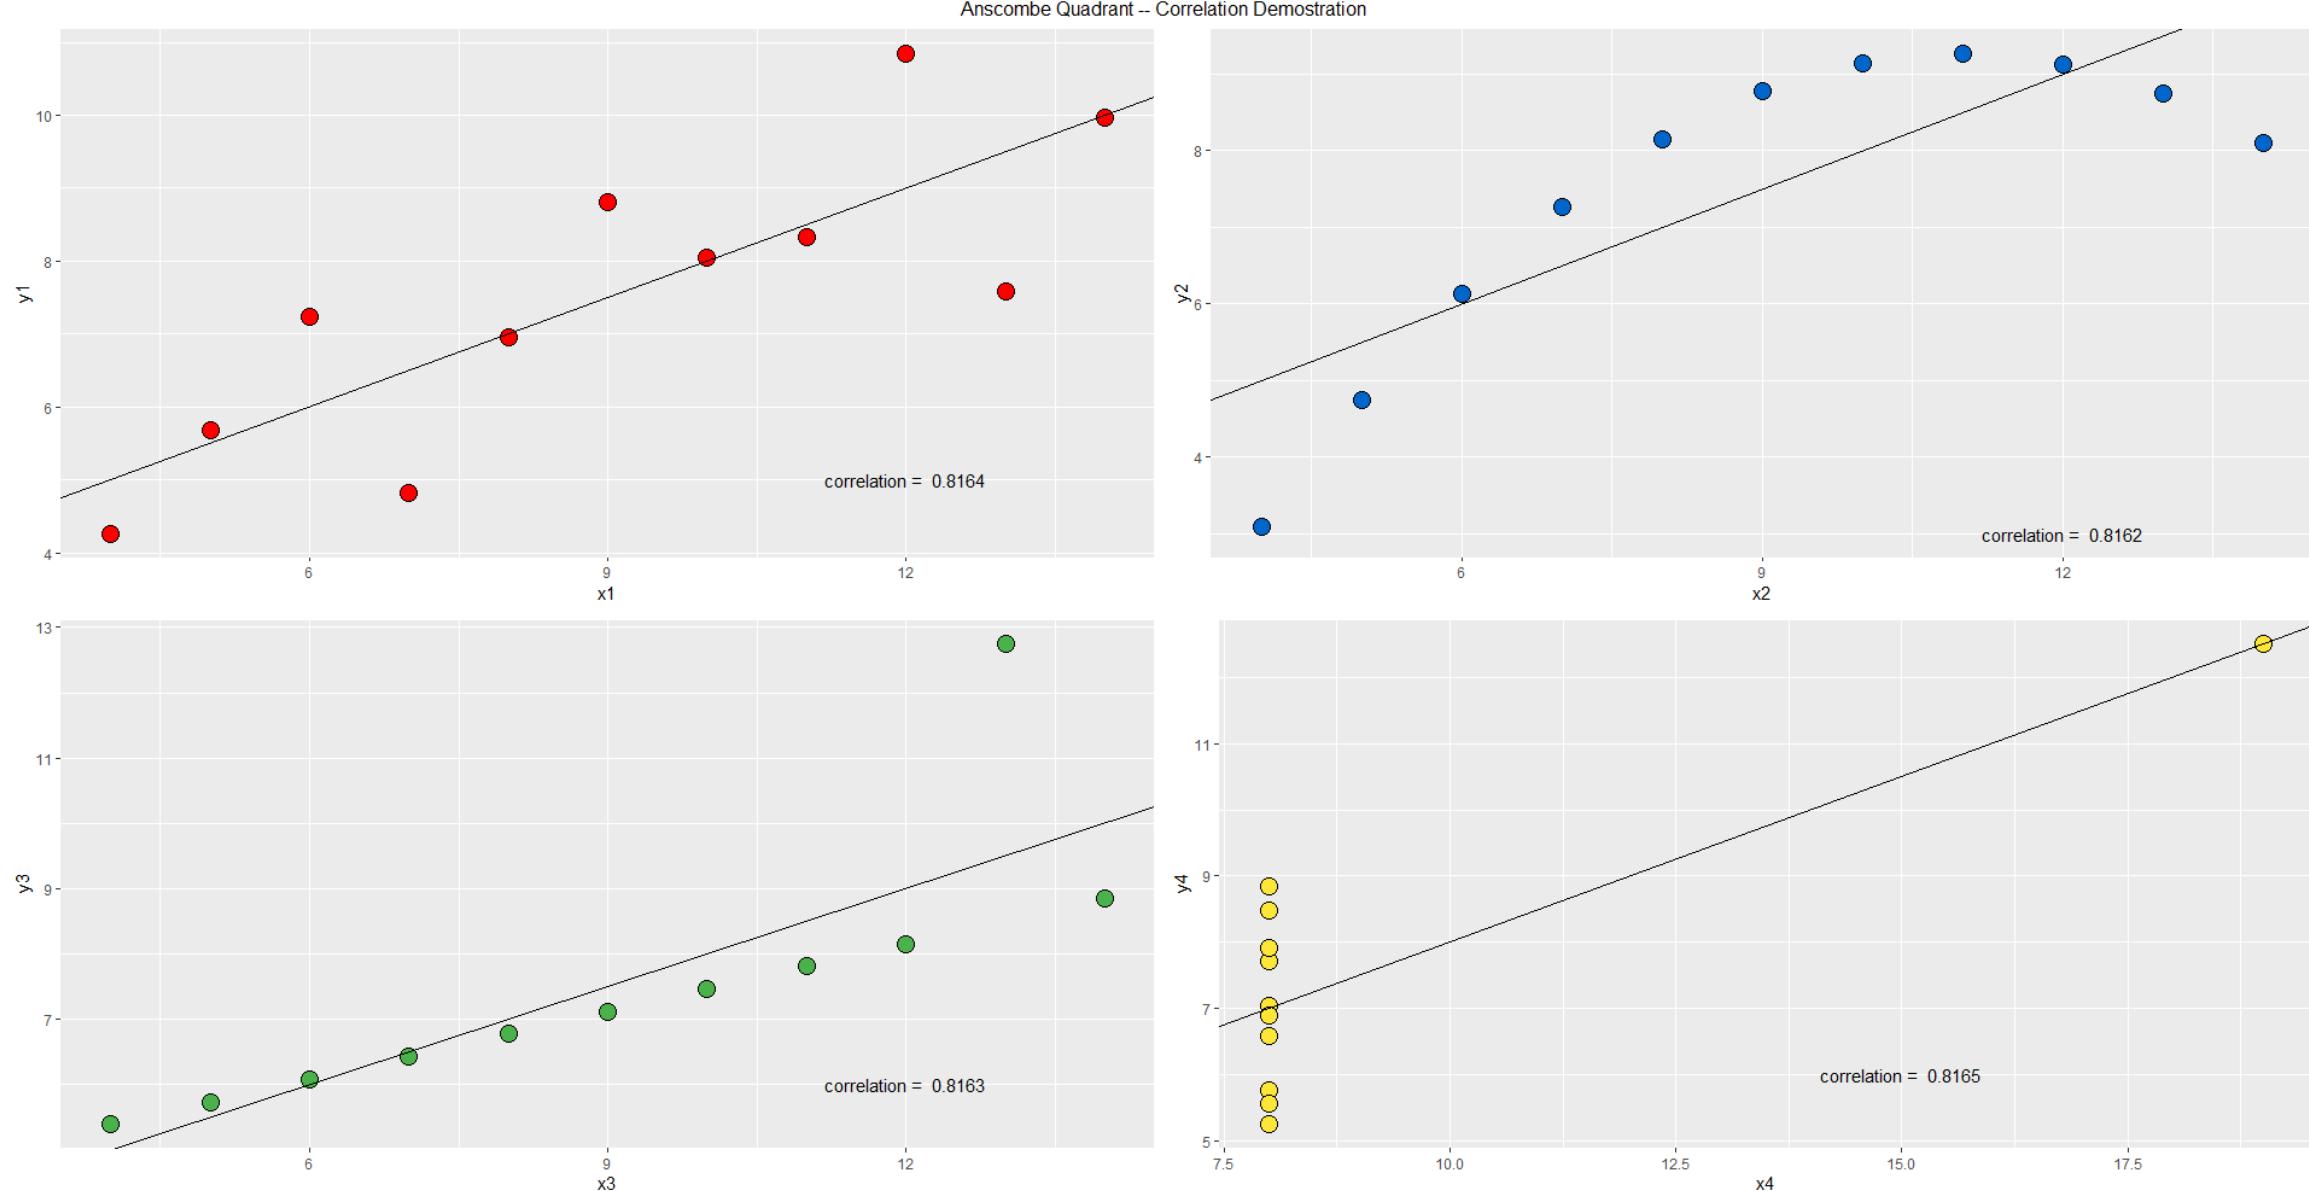
NO CORRELATION



Συντελεστής συσχέτισης του Pearson r (Pearson's correlation coefficient)

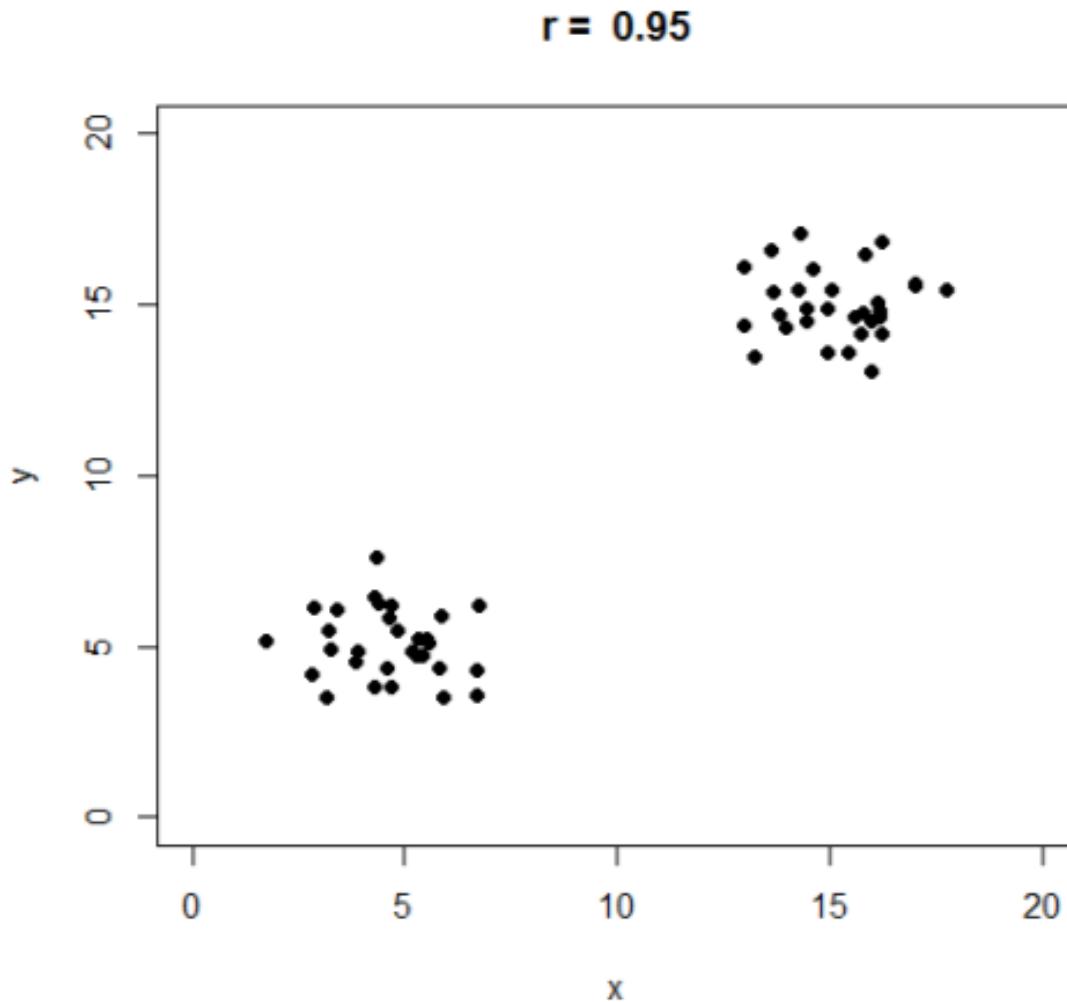


Ο συντελεστής συσχέτισης του Pearson r δεν είναι πάντα χρήσιμος



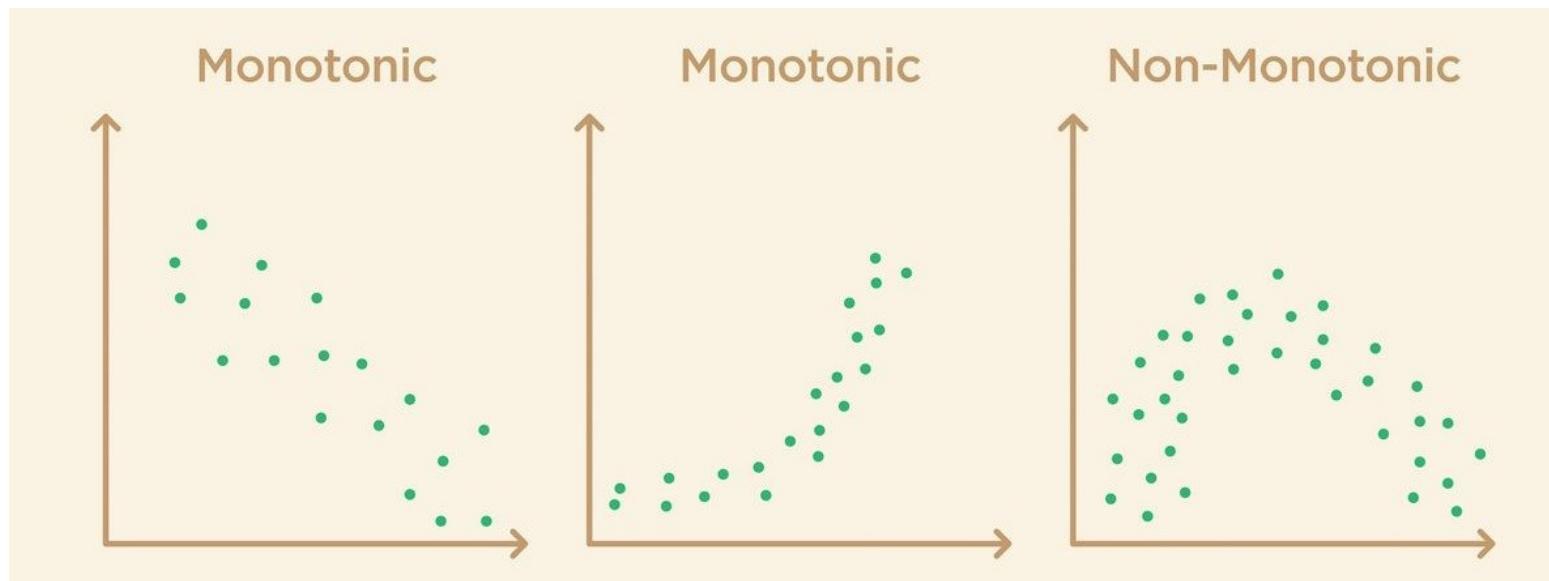
Ο συντελεστής συσχέτισης του Pearson r δεν είναι πάντα χρήσιμος

Περιορίζεται η χρήση του συντελεστή Pearson r όταν υπάρχουν **διακριτές υπο-ομάδες**.



Συντελεστής συσχέτισης του Spearman r_s

- Η **μη παραμετρική** εκδοχή του συντελεστή Pearson. Βασίζεται στις τάξεις (ranks) των μετρήσεων.
- Μετράει την κατεύθυνση και την ισχύ μιας **μονοτονικής σχέσης**
- Είναι **πιο ανθεκτικός** στην ύπαρξη ακραίων τιμών
- Χρησιμοποιείται και σε **διατάξιμες μεταβλητές**



Ερώτηση 1

Ο συντελεστής συσχέτισης του Pearson:

- ✗ (α) Εφαρμόζεται σε μη τυχαία δείγματα
- ✗ (β) Έχει μονάδες μέτρησης
- ✗ (γ) Χρησιμοποιείται όταν υπάρχουν ακραίες τιμές
- ✓ (δ) Προϋποθέτει η σχέση μεταξύ των ποσοτικών μεταβλητών να είναι γραμμική



Ερώτηση 2

Για τον συντελεστή συσχέτισης του Spearman ισχύει:

- (α) $-0.1 \leq r \leq +0.1$
- (β) $-1 \leq r \leq +1$
- (γ) λαμβάνει μόνο θετικές τιμές
- (δ) έχει μονάδες μέτρησης



Ερώτηση 3

Ο συντελεστής συσχέτισης του Spearman :

- ✓ (α) Εφαρμόζεται καλά όταν οι μεταβλητές έχουν μια μονοτονική σχέση
- ✗ (β) Δεν μπορεί να υπολογιστεί όταν η σχέση είναι γραμμική
- ✗ (γ) Προϋποθέτει οι μεταβλητές να είναι κανονικές
- ✗ (δ) Εφαρμόζεται καλά όταν τα δεδομένα έχουν την μορφή U



Ερώτηση 4

Τιμή του συντελεστής συσχέτισης του Pearson r ίση με:

- ✗ (α) -1 δείχνει τέλεια θετική συσχέτιση
- ✗ (β) 0.5 δείχνει ότι δεν υπάρχει συσχέτιση
- ✗ (γ) 1 δείχνει ότι δεν υπάρχει συσχέτιση
- ✓ (δ) -1 δείχνει τέλεια αρνητική συσχέτιση



Γραμμική Εξάρτηση

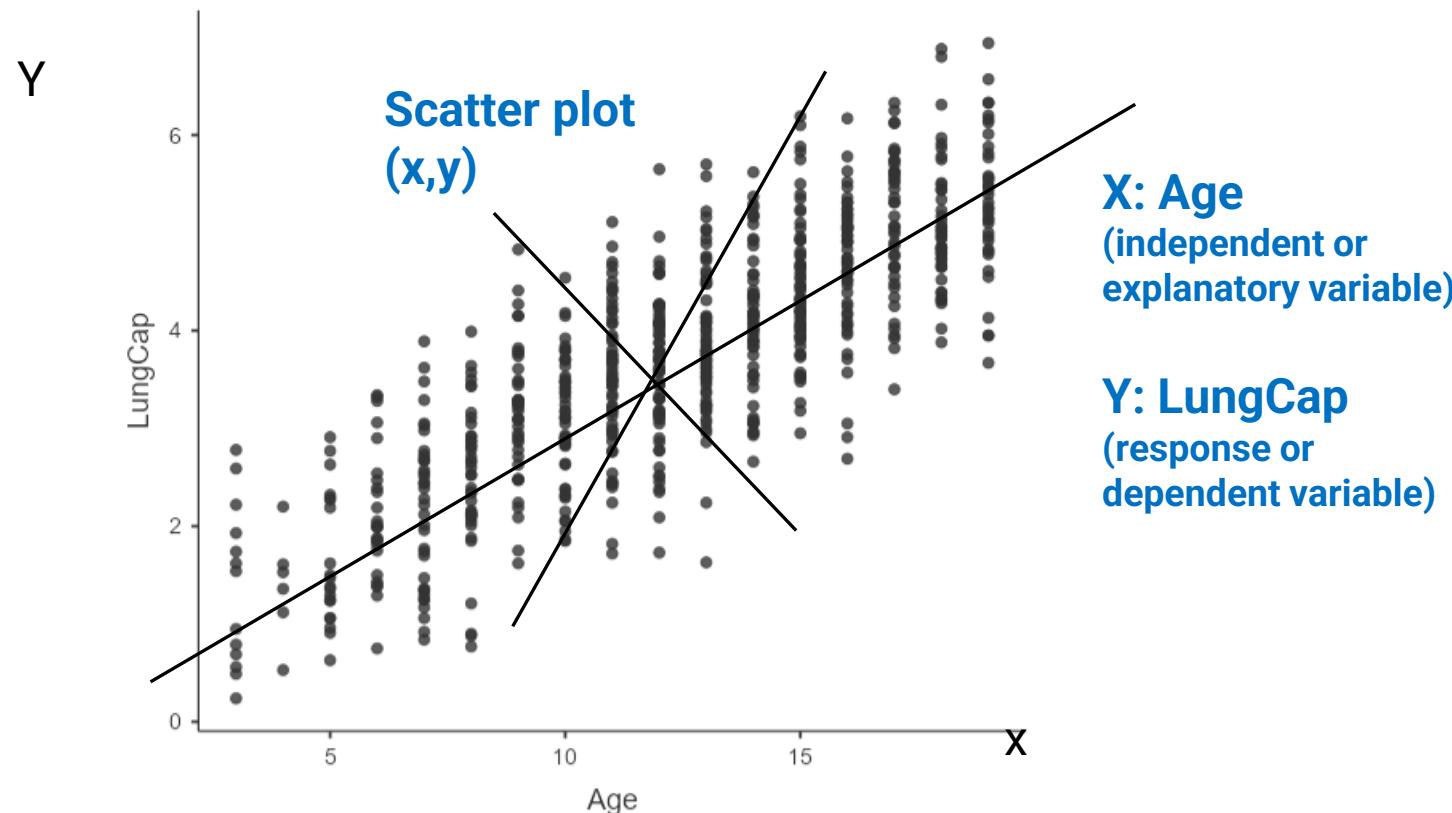
Απλή γραμμική εξάρτηση

Εξαρτημένη
μεταβλητή

$$y_i = a + \beta * x_i + \varepsilon_i \quad i=1,2,\dots,n$$

Ανεξάρτητη
μεταβλητή

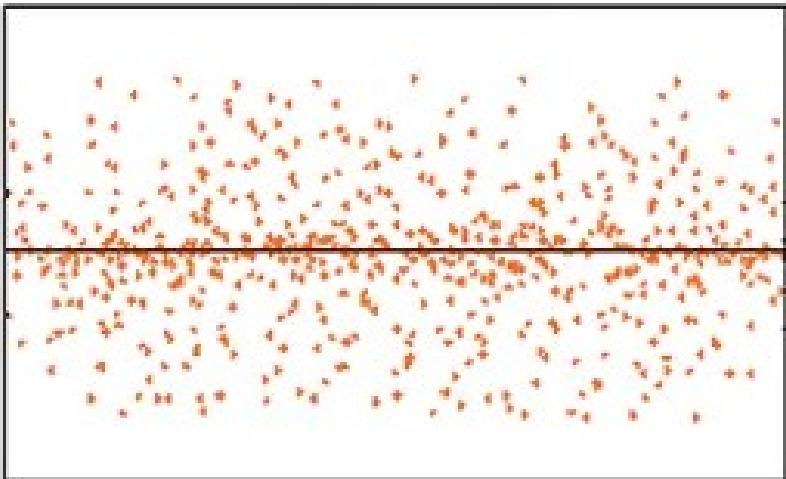
Random error



- **Γραμμική εξάρτηση των μεταβλητών X και Y**
- **Τα σφάλματα να είναι ανεξάρτητα (δηλ. να μην υπάρχει αυτοσυσχέτιση)**
- **Κανονική κατανομή των σφαλμάτων**
- **Ομοσκεδαστικότητα (homoscedasticity) των σφαλμάτων**
- **Να μην υπάρχουν επηρεάζουσες παρατηρήσεις (influential points)**

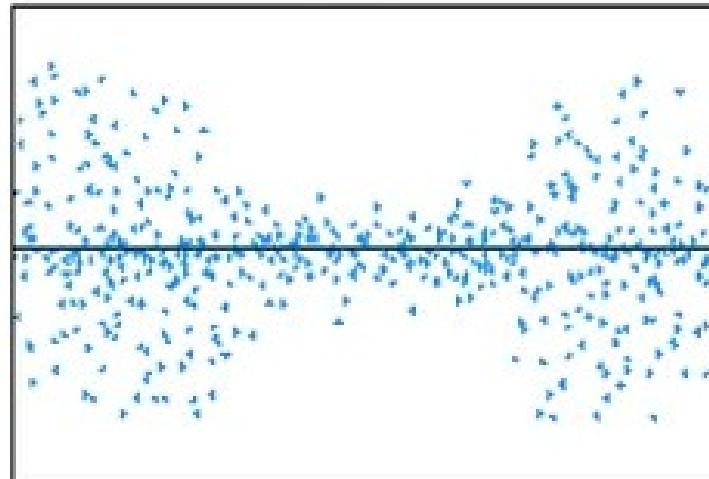
Ομοσκεδαστικότητα (homoscedasticity) των σφαλμάτων

Homoscedasticity



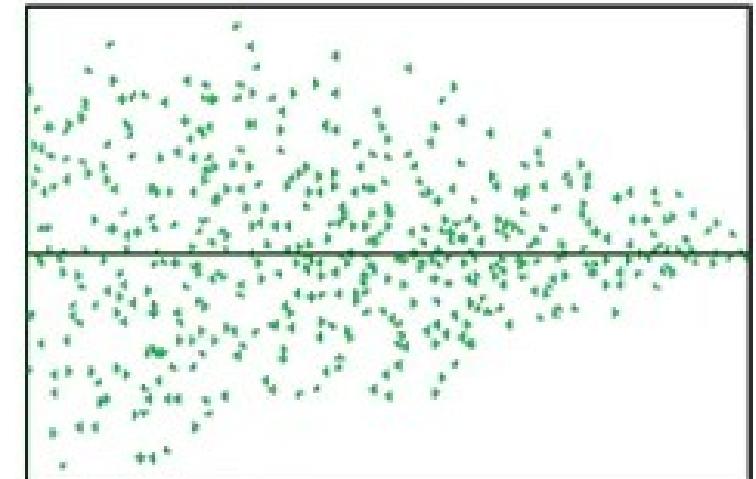
Random Cloud (No Discernible Pattern)

Heteroscedasticity



Bow Tie Shape (Pattern)

Heteroscedasticity



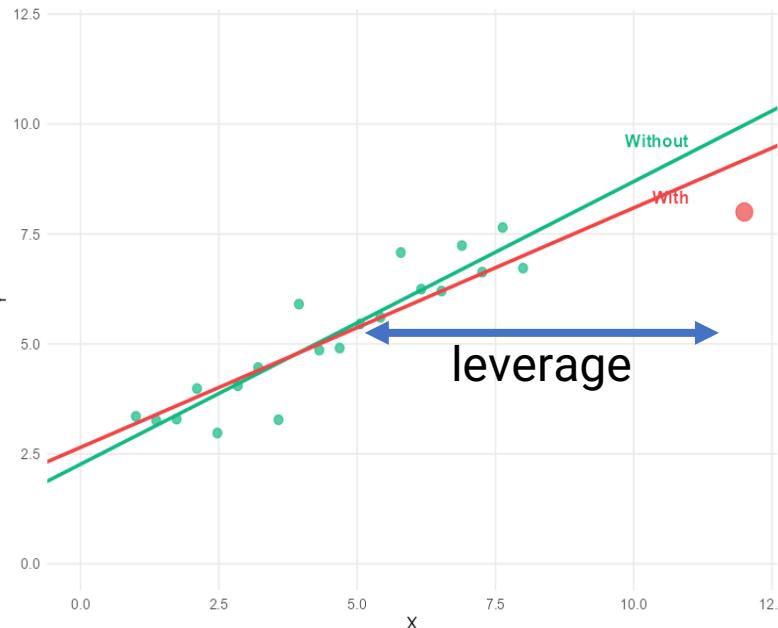
Fan Shape (Pattern)

Homoscedasticity vs Heteroscedasticity

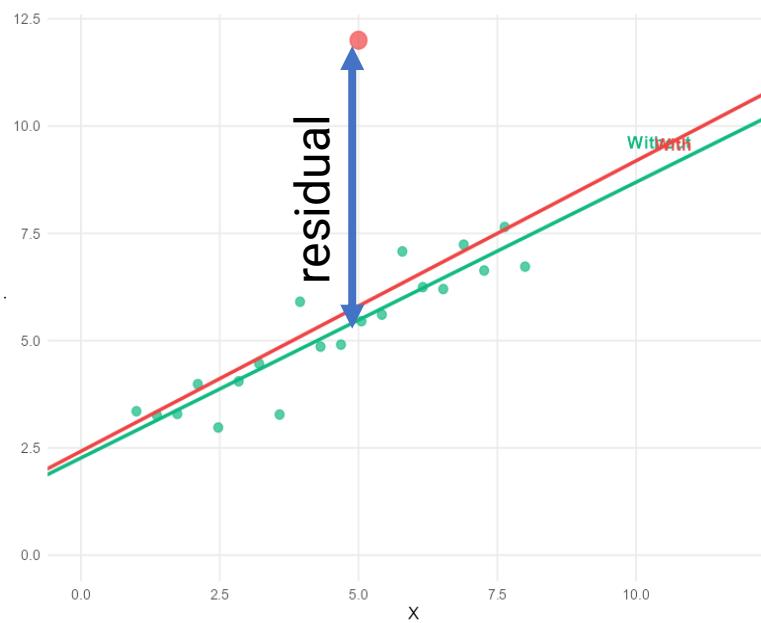


Επηρεάζουσες παρατηρήσεις (influential points)

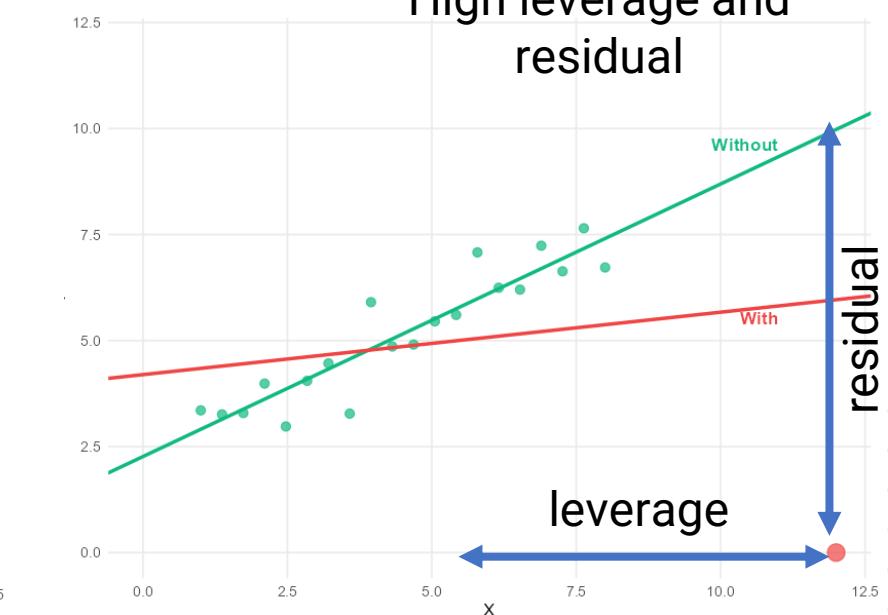
High leverage



High residual



Influential Point
High leverage and
residual



The leverage h (x -value) of the red point is much higher than the mean of X of the observations. However, the red point does not influence the model very much (not influential).

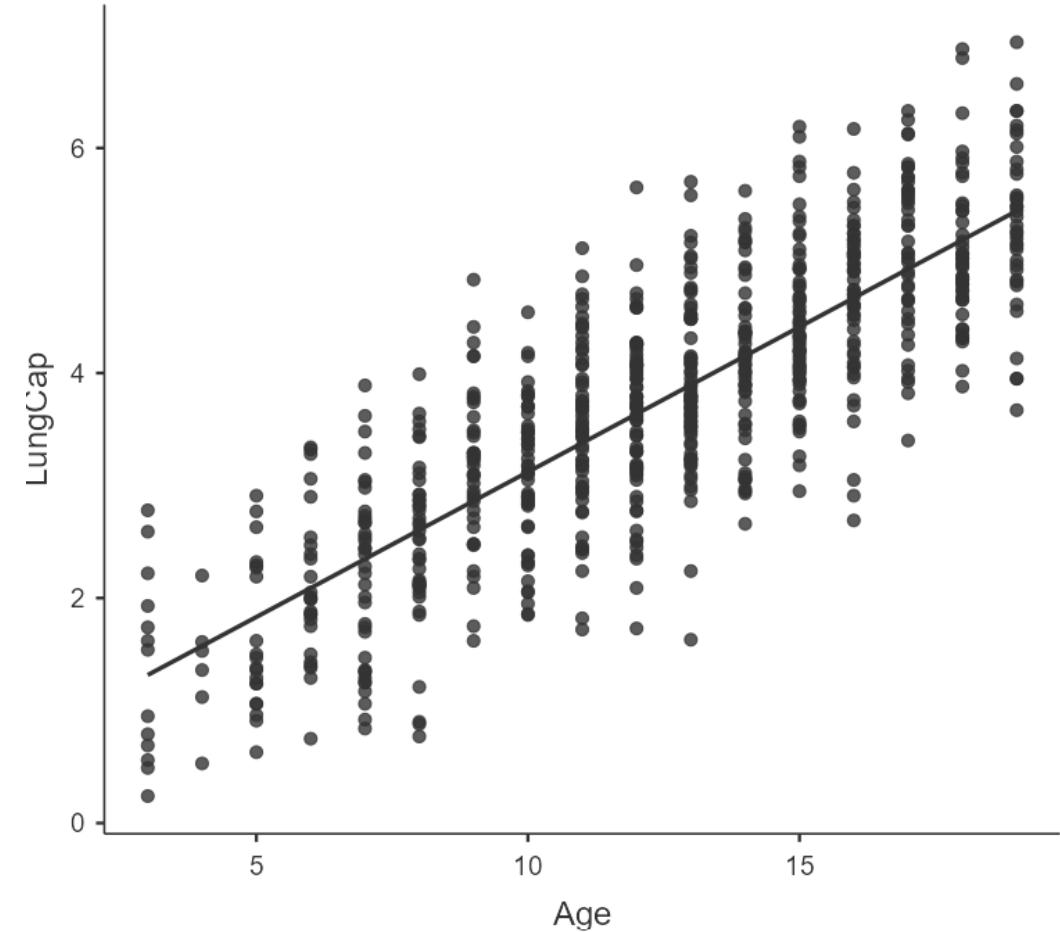
The residual (y -value) of the red point is much higher than the mean of Y of the observations. However, the red point does not influence the model very much (not influential).

The red point has both high leverage and a large residual, and therefore it has a strong influence on the model (influential point).

Απλή γραμμική εξάρτηση – Έλεγχος Υποθέσεων

$$\hat{y} = \alpha + \beta * X$$

- $H_0: \beta=0$ (no association)
- $H_1: \beta \neq 0$ (there is association)



Απλή γραμμική εξάρτηση – Ποσοτική ανεξάρτητη μεταβλητή

$$LungCap = 0.54 + 0.26 * Age$$

Αν αυξηθεί η ηλικία ενός ατόμου κατά ένα χρόνο π.χ. από τα 14 χρόνια στα 15 χρόνια, αυξάνεται **κατά μέσο** όρο η χωρητικότητα των πνευμόνων του κατά **0.26 L** (95%CI: 0.24 έως 0.27, p <0.001).



Συντελεστής προσδιορισμού:

$$R^2 = \frac{\text{explained variation}}{\text{total variation}} \quad (R^2 : 0 \text{ to } 1)$$

Μέτρο ‘καλής προσαρμογής’ του γραμμικού μοντέλου στα δεδομένα.

Κοντά στο 1 \Rightarrow μεγάλο ποσοστό της διακύμανσης της εξαρτημένης μεταβλητής ερμηνεύεται από την ανεξάρτητη μεταβλητή του μοντέλου.

Π.χ. για την περίπτωση της ποσοτικής μεταβλητής της ηλικίας (Age) βρίσκουμε $R^2 = 0.67$ και σημαίνει ότι 67% διακύμανσης της εξαρτημένης μεταβλητής (LungCap) ερμηνεύεται από την ανεξάρτητη μεταβλητή του μοντέλου (Age).